第 4 章　基于虚拟视点的位姿优化算法研究

基于全局特征的位置识别以召回率为目标，因此召回的图像中可能只有少量图像能提供有效的定位信息，为了解决这一问题，本章以基于全局特征的图像召回结果作为参考，额外召回与查询图像空间一致性以及共视程度较高的数据库图像，以此提高图像对应的3D点云中有效3D点的数量，从而实现更为准确的定位。将本文所提方法在单目视觉定位公开数据集Aachen day night上进行性能测试与比较，在使用相同SfM的情况下，本文方法相比于2020 ECCV VPR挑战赛的冠军方案Hloc表现出了更好的定位精度。

4.1　概述

六自由度的视觉位姿估计问题需要依赖已知的3D模型。通常该模型来自于SLAM方法或是SfM方法。为构建出更为精确的场景模型，从而较少建模误差对位姿估计的影响，本文使用SfM方法建立稀疏3D点云模型。该模型中的3D点均由数据库图像的2D匹配点三角化后得到，所以同一3D点会在多张数据库图像中被观测到，即一个3D点可能对应多个不同图像的2D点。因此在场景的稀疏点云模型中，每个3D点都与从对应数据库图像中提取得到2D点特征描述符相关联。

在在线定位阶段，对于给定的查询图像，依据第3章所述方法提取全局特征并进行位置识别，从而检索出若干候选图像。这些候选k图像及其对应的特征点组成了规模相对较小的候选点云集合。但是通过位置识别检索得到的图像位姿未必接近于查询图像的真实位姿，这些候选点云可能分散在场景中的不同区域，与查询图像真实位姿的可见区域交集较小。在这种情况下，可用来计算查询图像位姿的3D点数较少且其分布较为集中，因此通过非线性优化进行位姿估计时容易陷入局部最优解，导致位姿估计精度降低。针对这一问题，本文基于图像的共视性以及3D点的空间位置额外召回数据库图像，并依据数据库图像和点云的对应关系扩大候选点云规模以增大与查询图像真实位姿可见区域交集点云规模。此外，在查询图像与数据库图像存在昼夜、天气、季节等变化的条件下，非交集区域的点云可能会造成比较严重的干扰，从而导致无法定位或者给出错误的定位结果。对此本文基于参考位姿对候选3D点进行过滤，在减少点云规模的同时滤除部分噪点。

为计算查询图像位姿，需要提取其2D点特征并找出2D点和候选点云中3D点的正确匹配关系。这以一2D-3D匹配关系的建立方法大多为直接匹配法和基于图像匹配的间接匹配法。直接匹配法将查询图像2D点直接与3D点匹配，由于每一3D点都对应多个特征描述，故通常用特征描述均值表征该3D点。然而3D点本质是将数据库图像2D点依共视关系抽样得到的子集，即便候选图像中存在与查询图像完全一致的结果，查询图像2D点与候选点云匹配时仍会受到查询图像无关2D点的影响从而构建出无关2D点与3D点的错误匹配关系。针对这一问题，本文在基于图像匹配的间接2D-3D匹配法中引入虚拟视点可视性约束，该方法充分利用3D点的多个描述符信息进行匹配，并结合虚拟视点可视性约束提高正确匹配对比例。在此基础上对虚拟视点位姿进行迭代优化，以此保证在场景变化较大条件下的正确定位。

4.2　基于共视性和空间一致性的 3D 点召回

4.2.1　基于共视性的 3D 点召回

在进行 2D-3D 匹配时，需要尽可能多的召回数据库中查询图像可视区域 3D 点。然而基于图像检索的分级定位系统中，召回的 3D 点均为来自位置识别召回的数据库图像中三角化成功的 2D 点，因此当位置识别给出的数据库图像与查询图像重叠较少时，可供查询图像匹配的正确 3D 点数目有限，从而影响位姿估计精度。为提高查询图像可视区域 3D 点的召回率，需要在位置识别的基础上对候选点云进行补充。考虑到对于候选点云中的每个 3D 点，

与它处于同一空间区域的也有许多数据库点，尤其在纹理较为丰富的区域，一些方法是额外召回候选点云的空间近邻点。但是由于视角或者遮挡，某些与候选点云空间近邻的 3D 点可能在查询图像中不可见，这些 3D 点不会对位姿估计起到正面作用，因此本文不采用文献**错误!未找到引用源。**中所述方法依据 3D 点的空间近邻关系进行 3D 点召回。而是类似文献**错误!未找到引用源。**中的方式，依据候选点云和 SfM 模型中的共视信息额外召回 3D 点，共视召回如图 4-1 所示。

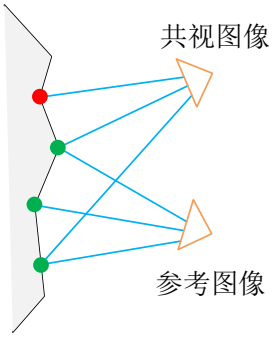

图 4-1 共视召回

假设由位置识别得到的数据库图像对应的 3D 点组成集合 $\mathbf{P}_{\mathrm{VPR}}$。因为基于共视信息的召回方式受位置识别的准确率影响较大，因此本文先用 RANSAC-PnP 方法对集合 $\mathbf{P}_{\mathrm{VPR}}$ 过滤，以此提高 $\mathbf{P}_{\mathrm{VPR}}$ 中查询图像可视区域 3D 点的准确率，从而得到依据 RANSAC-PnP 过滤后的 3D 点集合 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$。在此基础上，使用 SfM 模型的可见性信息对每个可以观察到 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$ 中 3D 点的数据库图像进行共视性投票，若 $\mathbf{p} \in \mathbf{P}_{\mathrm{VPR\text{-}F}}$ 在数据库图像中可见，则该图像得票数加一。然后，以得票数最高的数据库图像组成 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$ 的最佳可见图像，记为 I_{VBR}，以此实现基于共视性的图像召回。从数据库图像中寻找到 I_{VBR} 后，将 I_{VBR} 图像的 3D 点添加到 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$ 集合中，得到 3D 点集合 $\mathbf{P}_{\mathrm{VBR}}$。从而实现基于共视性的 3D 点召回。

4.2.2 基于空间一致性的 3D 点召回

在基于共视性的 3D 点召回过程中，由于 $\mathbf{I}_{\mathrm{VBR}}$ 的选择仅取决于 3D 点集合 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$ 的可见性，当 $\mathbf{P}_{\mathrm{VPR\text{-}F}}$ 对应的初始 2D 特征在查询图像中数量较少或分布不佳时，由这些点投票得到的数据库图像 $\mathbf{I}_{\mathrm{VBR}}$ 可能与查询图像只有部分重叠。这是因为 3D 点更多反应的是数据库图像之间的共视关系，而非查询图像与数据库图像的共视关系。因此，由数据库图像共视性召回的 3D 点集合 $\mathbf{P}_{\mathrm{VBR}}$ 与查询图像可能只存在部分交集。为尽可能多地召回数据库中查询图像的可见 3D 点，需要将与查询图像共视程度最高的数据库图像召回，因此需要对图像之间的共视程度进行衡量。一种直接的方法是依据两图像的射影变换关系计算变换后图像的重合比例。然而该射影变换关系由两图像的相对运动以及对应的相机内参给出，且对单目图像还需要计算空间点的深度，故计算射影变换的方法复杂度较高。因此通常的做法是依据对极几何约束去判断匹配点对是否正确，并通过 RANSAC 算法过滤出正确匹配对，从而计算满足空间一致性的匹配点对比例，作为空间一致性得分。

假设存在两图像分别为 I_1 和 I_2，它们观察到了相同的世界点 $\mathbf{P}$，将该点投影到两图像的成像平面，分别得到坐标 $\boldsymbol{p}_1$ 和 $\boldsymbol{p}_2$，如图 4-2 所示。

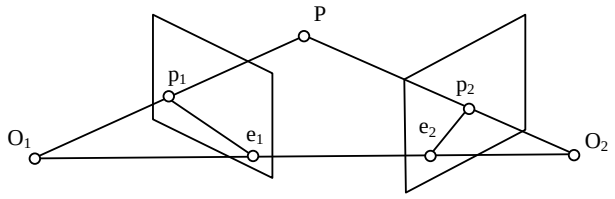

图 4-2 对极几何约束

图中O1和O2分别是两相机光心，由相机的小孔成像模型可知，射线$\overrightarrow{O_1\boldsymbol{p}_1}$与射线$\overrightarrow{O_2\boldsymbol{p}_2}$必然会相交于世界点P。因此$O_1$、$O_2$、P、$\boldsymbol{p}_1$和$\boldsymbol{p}_2$这5个点处于同一平面内，该平面被称为极平面。对于两图像观察到的其它世界点，O_1和O_2与该世界点可能会组成的新的极平面，因此构成了一个极平面族。因为O_1和O_2的位置不变，因此该极平面族均为绕连线O_1O_2所得，连线O_1O_2被称为基线。此外，成像结果已经确定，因此相机的成像平面也不会发生改变，所以基线与两成像平面的交点$\boldsymbol{e}_1$和$\boldsymbol{e}_2$也是固定的，它们被称为极点。

从图像I_1的角度来看，射线$\overrightarrow{O_1\boldsymbol{p}_1}$上的所有世界点都会被投影到$\boldsymbol{p}_1$上，因此射线$\overrightarrow{O_1\boldsymbol{p}_1}$确定了对应于$\boldsymbol{p}_1$的世界点可能出现的位置。同时，该射线在图像$I_2$成像平面上的投影$\overrightarrow{\boldsymbol{e}_2\boldsymbol{p}_2}$也对应于$\boldsymbol{p}_1$的正确匹配点可能出现的位置。同理，从图像$I_2$的角度来看，$\overrightarrow{O_2\boldsymbol{p}_2}$确定了对应于$\boldsymbol{p}_2$的世界点可能出现的位置，$\overrightarrow{\boldsymbol{e}_1\boldsymbol{p}_1}$对应于$\boldsymbol{p}_2$的正确匹配点可能出现的位置。由于$\overrightarrow{\boldsymbol{e}_2\boldsymbol{p}_2}$和$\overrightarrow{\boldsymbol{e}_1\boldsymbol{p}_1}$具备明确的含义，通常称它们为极线。如果没有给定正确的匹配，那么就需要在极线上进行匹配点搜索，这会带来巨大的计算量，因此通常的做法是用特征匹配的方式替代极线搜索，从而找到正确的2D匹配对$\boldsymbol{p}_1$和$\boldsymbol{p}_2$。在已知多个正确匹配点对的情况下，基于极平面上的几何关系，就可以估计出相机的相对运动，从而找到图像特征间的空间关联。

假设在I_1的坐标系下世界点坐标为$\mathbf{P}=\left[X,Y,Z\right]^T$，依据相机的小孔成像模型，可知该点投影到两图像的成像平面像素坐标系下的坐标满足

$$s_1\boldsymbol{p}_1=\mathbf{K}_1\mathbf{P},\quad s_2\boldsymbol{p}_2=\mathbf{K}_2\left(\mathbf{R}_{21}\mathbf{P}+\mathbf{t}_{21}\right) \tag{0-1}$$

其中，$\mathbf{K}_1$是图像I_1对应的相机内参，$\mathbf{K}_2$是图像I_2对应的相机内参。s_1、s_2分别是世界点$\mathbf{P}$到光心O_1和O_2的距离。$\mathbf{R}_{21}$和$\mathbf{t}_{21}$分别表示从图像I_1的相机坐标系到图像I_2的相机坐标系的旋转变换和平移变换，即两图像的相对运动。现在，取

$$\boldsymbol{x}_1=\mathbf{K}_1^{-1}\boldsymbol{p}_1,\quad \boldsymbol{x}_2=\mathbf{K}_2^{-1}\boldsymbol{p}_2 \tag{0-2}$$

其中，$\boldsymbol{x}_1$和$\boldsymbol{x}_2$分别为世界点在两图像的归一化成像平面上的坐标。将式(0-2)带入(0-1)中，可以得到

$$s_2\boldsymbol{x}_2=s_1\mathbf{R}_{21}\boldsymbol{x}_1+\mathbf{t}_{21} \tag{0-3}$$

式(0-3)描述了两图像中对应点的射影变换关系，对其两边同时左乘$\mathbf{t}_{21}^{\wedge}$，得到

$$s_2\mathbf{t}_{21}^{\wedge}\boldsymbol{x}_2=s_1\mathbf{t}_{21}^{\wedge}\mathbf{R}_{21}\boldsymbol{x}_1 \tag{0-4}$$

然后，再对式(0-4)两边左乘$\boldsymbol{x}_2^{\mathrm{T}}$，因为$\mathbf{t}_{21}^{\wedge}\boldsymbol{x}_2$同时与$\boldsymbol{x}_2$和$\mathbf{t}_{21}$垂直，因此有

$$\boldsymbol{x}_2^{\mathrm{T}}\mathbf{t}_{21}^{\wedge}\mathbf{R}_{21}\boldsymbol{x}_1=0 \tag{0-5}$$

重新带入 $\boldsymbol{p}_1$、$\boldsymbol{p}_2$ 到式(0-5)中，有

$$\boldsymbol{p}_2^{\mathrm{T}}\mathbf{K}_2^{-\mathrm{T}}\mathbf{t}_{21}^{\wedge}\mathbf{R}_{21}\mathbf{K}_1^{-1}\boldsymbol{p}_1=0 \tag{0-6}$$

式(0-5)和式(0-6)都被称为对极约束，该约束描述了图像 I_1 的光心 O_1、图像 I_2 的光心 O_2、世界点 $\mathbf{P}$ 这三个点的几何共面的事实。同时该约束耦合了两图像的相对运动以及成像模型参数，将它们抽取出来，可以得到两个矩阵，称为本质矩阵和基础矩阵，分别用符号 $\mathbf{E}$ 和 $\mathbf{F}$ 表示，为

$$\mathbf{E}=\mathbf{t}_{21}^{\wedge}\mathbf{R}_{21},\quad \mathbf{F}=\mathbf{K}_2^{-\mathrm{T}}\mathbf{E}\mathbf{K}_1^{-1} \tag{0-7}$$

其中，本质矩阵描述的是两图像成像平面的相对变化，而基础矩阵则描述了两图像像素坐标系的相对变化。借助于这两个表示，可以进一步简化对极约束

$$\boldsymbol{p}_2^{\mathrm{T}}\mathbf{F}\boldsymbol{p}_1=\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1=0 \tag{0-8}$$

通常的定位场景中，数据库图像的相机内参和查询图像的相机内参都能提前给定，此时使用的对极约束形式为 $\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1=0$。而通过特征点匹配算法，能给出可能存在错误匹配对的若干匹配点，因此对错误匹配点的滤除有两种方法，一种方法是依据对极约束构建线性最小二乘问题，求解该问题估计出本质矩阵，然后将匹配点对中超过对极约束阈值的滤除；另一种方法则是通过 RANSAC 算法在计算本质矩阵的同时过滤错误匹配点对。因为后一种方式更为稳健，因此为常用的本质矩阵估计方法，该方法流程如下：

（1）从匹配点对集合里面随机选取 8 个匹配点对；

（2）使用 8 点法求解本质矩阵；

（3）依据本质矩阵的内在性质调整本质矩阵；

（4）依据本质矩阵计算各匹配点对的辛普森距离，并统计内点个数；

（5）重复以上过程若干次，选择内点数最多的结果；

（6）用最终得到的所有内点构建优化问题，计算本质矩阵。

该方法流程中所述的本质矩阵的内在性质来自于其 $\mathbf{t}_{21}^{\wedge}\mathbf{R}_{21}$ 的形式，可以证明其奇异值为 $[\sigma,\sigma,0]^{\mathrm{T}}$ 的形式。辛普森距离的含义是使一阶误差最小的一阶误差。通过拉格朗日乘子法，可计算出对极约束 $\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1=0$ 所对应的辛普森距离为

$$d\left(\boldsymbol{x}_1,\boldsymbol{x}_2\right)=\frac{\left(\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1\right)^2}{\mathbf{J}\mathbf{J}^{\mathrm{T}}} \tag{0-9}$$

其中，$\mathbf{J}$ 为函数 $f\left(\boldsymbol{x}_1,\boldsymbol{x}_2\right)=\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1$ 的雅可比，为

$$\mathbf{J}=\begin{bmatrix}\dfrac{\partial\left(\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1\right)}{\partial x_1} & \dfrac{\partial\left(\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1\right)}{\partial y_1} & \dfrac{\partial\left(\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1\right)}{\partial x_2} & \dfrac{\partial\left(\boldsymbol{x}_2^{\mathrm{T}}\mathbf{E}\boldsymbol{x}_1\right)}{\partial y_2}\end{bmatrix} \tag{0-10}$$

因为本质矩阵反应了匹配点对的空间位置关系，因此可以将RANSAC算法估计本质矩阵时的内点比例作为两图像匹配点对空间一致性的衡量标准。然而该方法的时间复杂度较高，遍历地对所有数据库图像计算空间一致性得分并不可取。结合图像共视性，本文将4.2.1中与 $\mathbf{P}_{\text{VPR-F}}$ 共视点数较多的前10张图像保留，并对这些图像以及VPR图像依次打分，将相似度得分最高的图像作为基于空间一致性找到的最佳数据库图像，记为 I_{SBR}。然后像在4.2.1中一样，收集 I_{SBR} 中所有可见的3D点，添加到点集合 $\mathbf{P}_{\text{VBR}}$ 中，得到点集合 $\mathbf{P}_{\text{VSBR}}$。

图 4-3 RANSAC 过滤匹配点

对查询图像和数据库图像使用RANSAC计算得到的结果如图4-3所示。其中绿色点和线代表正确匹配的2D点对，红色点则表示辛普森距离较大的特征点。然而空间一致性校验使用的RANSAC算法具有很高的计算复杂度，当需要校验的图像数量较多时会带来较高的定位时延，因此本文采用Superglue网络的特征匹配平均得分作为空间一致性得分计算的简化算法，从而加快空间一致性召回速度。

4.3 基于虚拟视点的位姿优化

4.3.1 虚拟视点特征提取

在给定候选点云的情况下，可以通过使用所有匹配对的方式计算查询图像位姿，但是由于匹配结果受到定位场景变化的影响较大，当查询图像与数据库图像存在昼夜、季节、天气等差异时会导致定位误差增大。不同于常规方法，本文尝试将虚拟视点逐渐对齐到查询图像视点，以此减轻场景差异导致的定位性能降低。

在SfM模型中的真实视点由其位姿、可视2D特征点、相机模型这三者描述。虚拟视点同样需要具备这些内容，其位姿可通过直接指定的方式获得，为方便匹配，相机模型可以使用查询图像相机参数。因此还需要添加2D特征点到虚拟视点中，本文称之为虚拟视点特征提取。

若给定场景点云模型及相机内参，可以将场景点云投影到场景中任何位置和视角下的相机像素平面。这是虚拟视点合成技术的基本原理。不过目前的虚拟视点合成技术主要应用于全景视频或图像的生成中，依据离散参考视点的图像生成连续视点下的图像，从而满足全景图像和视频中视点连续切换的需求。因为需要得到虚拟视点下较为完整的图像，所以通常是使用 RGBD 相机获取图像的稠密点云，再重投影到虚拟视点上，并进行空洞填充以及多视点融合，得到完整的图像。当视角变化太大时，遮掩导致的像素缺失比较严重，因此通常来说虚拟视点和参考视点的不会有太大的位姿差异。而在本节所采用的定位框架中，场景地图是 SfM 算法得到的稀疏点云模型，故无法如文献**错误!未找到引用源。**中那样直接使用虚拟合成的完整图像扩充数据库，而是采用类似文献**错误!未找到引用源。**中的做法，使用数据库中已存在的地图点云生成只具备稀疏特征的虚拟视点用以匹配和位姿估计。这些稀疏特征来自于场景模型，将模型中的 3D 点映射到虚拟相机的像素平面上，只保留映射在合理范围内的特征点，就可以得到该虚拟视点的局部特征点。然而对于任意指定的虚拟视点位姿，仅依靠特征点像素坐标的约束很容易会选取到实际不可视的特征点。比如某些特征点在查询位姿下因被障碍遮挡而不可视，但是这些特征点的空间位置处于相机视角内，仅依据重投影区域约束很容易将其添加到虚拟视点特征中，从而造成干扰。这些处于虚拟视点视角内的不可视点可以大致分为两类，一类特征点受到较大遮挡，除非处于与虚拟视点视野差异较大的视点，否则不可能看到这类特征；另一类特征点仅受到较小遮挡，虚拟视点位姿的略微变换就有可能使得这类特征可见。第一类特征点是主要的不可视点来源，因此需要对其进行去除。

因为能正确定位时，总的候选点云中必然存在足够数量的查询位姿可视点，即在候选图像中存在与查询图像共视点数量较高的数据库图像，这类图像的特征点中，除非位姿差异较大否则不可见，因此数据库中与虚拟视点空间近邻图像的特征点中必然不包含该类特征。类似于基于 VPR 的图像召回，可以对数据库图像中与虚拟视点位姿近邻的图像进行共视性筛

选以及空间一致性筛选以组成候选点云，然后依据重投影区域约束对候选点云过滤，虚拟视点特征选择如图 4-4 所示。

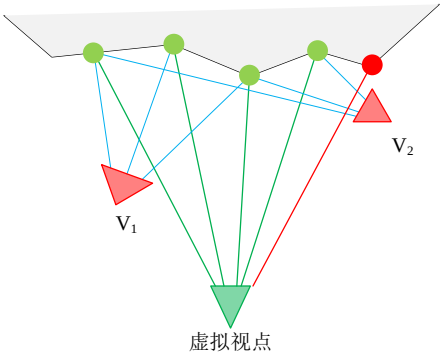

图 4-4 虚拟视点特征选择

图 4-4 中假设通过图像匹配后得到查询图像的两张匹配数据库图像，其视点对应 V_1 和 V_2。由点特征的 2D-2D 匹配关系，可找到查询图像 2D 点对应的 3D 点，大部分 3D 点如图 4-4 中的绿点所示，可以重投影到虚拟视点可视范围内。但是因为可能存在 2D 点的误匹配，也会存在部分 3D 点不属于虚拟视点可视点，如图 4-4 中的红色点所示，该 3D 点重投影到虚拟视点的像素坐标后超出了图像尺寸，因此被剔除。由于组合了多个图像的 3D 点信息，使用虚拟视点特征分布能更接近于查询图像，以其作为参考召回的 3D 一定程度上克服分级检索框架下的多视角定位困难的问题。而且也能给出更多有效 2D-3D 匹配点供位姿估计。

4.3.2 基于虚拟视点的位姿优化

经过位置识别、共视性召回、空间一致性召回后的点集合中会包含大量处于查询位姿视野外的 3D 点。如果使用直接法进行 2D-3D 匹配，因为特征匹配过程只考虑特征描述子的相关程度，这些不可视点中不可避免地存在某些点处于与查询图像局部相似的区域，此时这些不可视点就会对特征匹配造成干扰，取代正确匹配结果，使得正确匹配点对所占比例下降。由于 RANSAC 算法是寻找内点数最多的匹配点集，当正确匹配点对数量占比较小时，部分错误匹配点集合可能成为内点数最多的匹配点集，此时 RANSAC 算法难以给出正确的 3D 点滤除结果。因此本文采用基于图像匹配的间接 2D-3D 匹配法。将查询图像与候选数据库图像进行 2D-2D 匹配，再依据数据库图像的 2D 点和 3D 点对应关系筛选出查询图像与候选点云的 2D-3D 匹配对。此方法能较为简单地利用 3D 点的多个 2D 描述符进行匹配，并可通过估计查询图像和数据库图像的本质矩阵进行空间一致性校验来滤除部分误匹配对，因此能获取更多的正确匹配对，从而得到最大匹配子集。对该匹配集合应用 RANSAC-PnP，就能得到用以计算位姿的 2D-3D 匹配对。

然而，由于位置识别得到的候选点云中查询图像可视点可能较少，依然会存在匹配对数目较少的情况，例如存在昼夜、天气、季节等变化的条件下。此时会无法定位或者给出错误的定位结果。为减轻该影响，本文以基于图像匹配的间接 2D-3D 匹配点对计算虚拟视点位姿，然后进行召回操作以恢复丢失的匹配点对，从而提高正确匹配点对的比例，方法流程如图 4-5 所示。

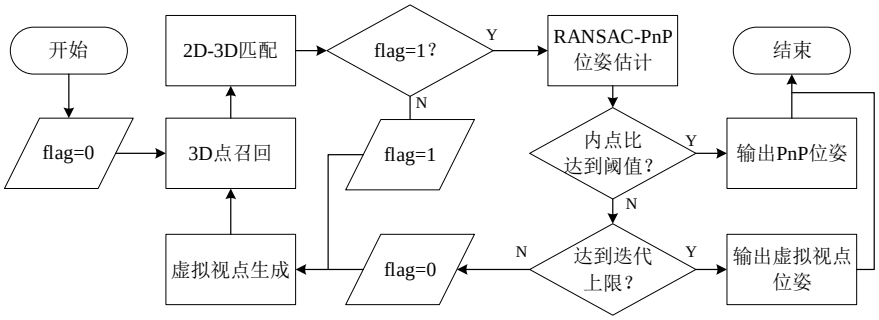

图 4-5 基于虚拟视点的位姿优化流程图

初始虚拟视点位姿为空间一致性召回的 I_{SBR} 位姿，通过 RANSAC-PnP 算法对其进行更新。为加快位姿优化速度，每次更新虚拟视点后仅进行一次额外点召回。直到 RANSAC-PnP 的内点比例达到所设阈值，或者迭代次数达到上限输出位姿。假设局部定位场景如图 4-6 所示，可将上述图 4-5 流程进行可视化表示。

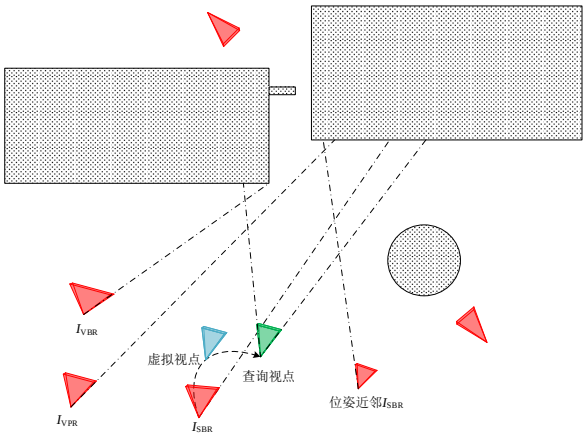

图 4-6 局部定位场景

图 4-6 中红色金字塔表示数据库图像视点，绿色金字塔表示查询图像的真实视点，蓝色金子塔表示通过对查询图像进行位姿估计而得到的虚拟视点。假定在该区域中通过 VPR 找到的查询图像为 I_{VPR}，对 I_{VPR} 的共视图像进行基于共视性以及空间一致性的召回，分别得到与查询视点共视程度较高的 I_{VBR} 以及空间一致性较高的 I_{SBR}。将 I_{SBR} 作为虚拟视点位姿的初始值，寻找其位姿近邻图像中与查询图像空间一致性最高的图像加入到候选图像中。然后进行基于图像匹配的间接 2D-3D 匹配，获取所有潜在的正确匹配对。对这些匹配对依据 3D 点在虚拟视点下的重投影区域限制进行筛选。并使用剩下的匹配对计算新一轮的虚拟视点位姿。此迭代过程中依据虚拟视点空间位姿检索图像，能解决查询图像位姿近邻图未被完全检索时，VBR 以及 SBR 过度依赖 VPR 共视图导致潜在匹配点对丢失的问题。因 PnP 算法在内点数占比较大时收敛速度较快，因此仅需较少轮次的迭代即可实现位姿求解。

4.4 系统性能分析

为分析定位性能，在定位数据集 Aachen Day-Night 上进行测试。该数据集提供了使用 SIFT 局部特征点以及最近邻匹配，并通过 colmap 算法建立的场景模型地图。因为本文所用的图像点特征提取方法为 Superpoint，特征匹配方法为 Superglue，因此需要重新建立场景模型地图，在重新建图的过程中使用官方模型的位姿数据筛选图像匹配对以大幅减少建图所需时间。将 Superpoint 特征点和 Superglue 获取的 2D-2D 匹配点对导入到数据库中，使用 colmap 算法建图，最终建立出来的场景模型俯视图如图 4-7 所示。

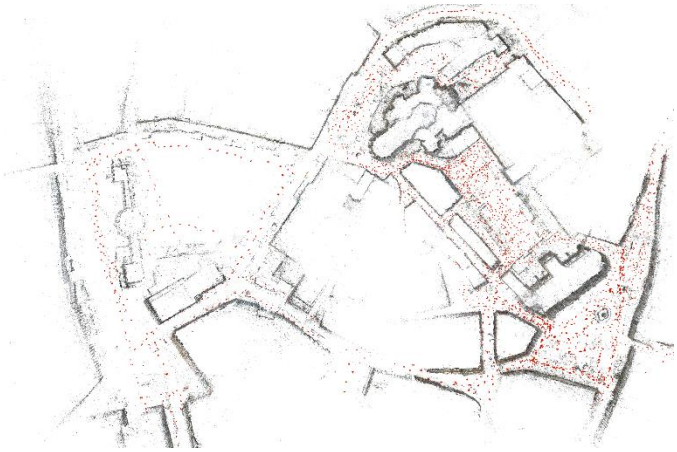

图 4-7 Aachen Day-Night SfM 模型

图 4-7 中的红点是建图成功注册的数据库图像，这些图像中都存在 3D 点并且位姿已经通过全局优化的方式估计出来了，黑色的点就是成功三角化的 2D 特征点。在建图过程中，部分数据库图像位姿估计误差较大，这些图像不会被注册到模型之中，因此模型中的图像只是数据库图像的子集。

首先评估本文所提基于图像共视性和空间一致性的召回方法有效性。随机从查询数据集中选择一张图像如图 4-8 所示。

图 4-8 查询图像

基于图像全局特征相似度召回的方法仅与图像外观有关而与位置无关，因此在分级定位时通常使用该方法进行查询图像相关图像的召回。然而随着召回图像数量增长，相似度较低的图像中与查询图像相关的数据库图像数量出现频率降低。由于图像匹配时间与召回图像数量成正比例关系，若仅依据图像全局特征的相似性进行召回，随着召回图像数量增长，提升定位精度所需要的时间代价将过于昂贵。因此本文在基于全局特征召回部分图像后，不再使用全局特征继续召回，而是使用本章所述的基于共视性方法进行图像召回。对图 4-8 应用第 3 章所述的方法进行位置识别以检索 30 张数据库图像，并取相似度最高的前 20 张图像用以进行基于共视性的图像额外召回。取相似度较低的后 10 张图像作为基于全局特征方法的额外召回结果；取共视 3D 点数最多的前 10 张数据库图像作为基于共视性的额外召回结果。这些召回结果如图 4-9(a)、(b)所示。

(a) 基于全局特征的召回

(b) 基于共视性的召回

图 4-9 额外召回结果对比

根据图 4-9 中的图像召回结果可以看出，相比基于全局特征的召回方法，基于共视性的召回方法能检索出更多与查询图像相关的数据库图像，因此能为下一步的位姿估计提供更多有价值的信息。然而，仅仅依据共视性的召回结果受到基于全局特征的召回结果的较大影响。当因为视觉外观的混淆导致错误结果占比较多时，共视性召回的结果会更倾向于寻找混淆的错误结果。因此还需要结合图像的空间一致性进行更为准确的图像召回。

对与查询图像相似性最佳的前 20 张数据库图像使用 Superglue 方法进行匹配，将匹配特征点对进行 RANSAC 空间一致性校验，并计算空间一致性评分。取空间一致性评分最高的数据库图像作为参考，对其进行基于空间一致性的图像额外召回，召回结果如图 4-10 所示。

图 4-10 基于共视性和空间一致性的召回

对比图 4-10 与图 4-9（b）中结果可见，结合图像的空间一致性进行共视召回后，与查询图像相关的召回结果所占比例增大了，且召回图像的姿态更接近查询图像。本章在表 4-1 所示环境中下对比 hloc 以及本文所提位姿优化方法。

表 4-1 测试环境配置

软硬件	配置
显卡	Nvidia RTX3060 Laptop 6GB 显存
CPU	AMD Ryzen 7 5800H with Radeon Graphics 3.20 GHz
CUDA	CUDA 11.7
显卡驱动	Nvidia 515.65.01
Pytorch	1.11.0+cu115
torchvision	0.12.0+cu115

对 Aachen 数据集的查询图像使用 Superpoint 提取图像点特征，Superglue 进行特征匹配，并召回 50 张数据库图像。此时的定位性能如表 4-2 所示。

表 4-2 Aachen Day-Night 数据集定位结果

方法	day 数据集			night 数据集			位姿优化时间(ms)
	0.25m, 2°	0.5m, 5°	5m, 10°	0.25m, 2°	0.5m, 5°	5m, 10°	
Hloc[25]	88.6%	95.4%	98.3%	86.7%	92.9%	99.00%	288
本文方法（快速召回）	89.0%	95.6%	98.4%	86.7%	92.9%	99.00%	347
本文方法（isbr+ivbr）	**89.0%**	**96.0%**	**98.4%**	86.7%	92.9%	99.00%	509

从表 4-2 中结果可见，本文所提的位姿估计方法相比之下具备更好的精度效果。相比于 ECCV 2020 VPR 挑战赛的冠军方案 Hloc，本文方法以快速空间匹配的方法进行 3D 点召回时，具备较高的位姿估计精度以及较好的位姿优化时间。而使用空间一致性进行图像召回的情况下，本文所提方法能取得较高的定位精度提升。

为评估该方法的泛用性，在实验室制作数据集图像并标注其每一图像的位置和姿态进行位姿估计，实验环境如图 4-11 所示。

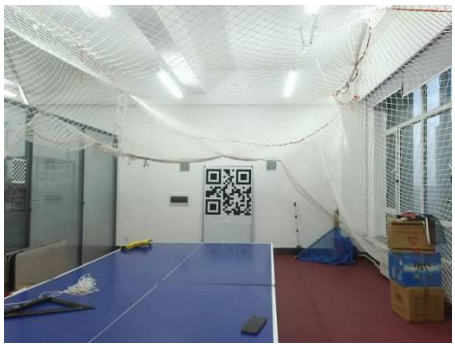

图 4-11 泛化性测试环境

在距离墙面 2 米到 7 米的范围内采集了多种视角下的图像，对每张图像测量其位置和旋转角作为建图和测试的基准。选取其中部分作为建图以及计算坐标变换关系的图像，剩余部分作为定位测试的图像。部分测试图像如图 4-12 所示。

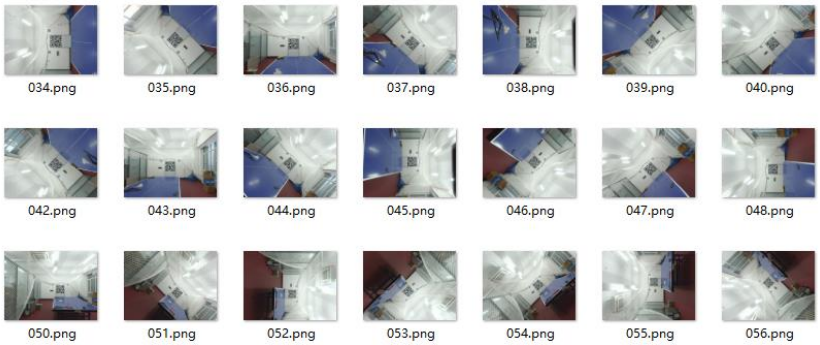

图 4-12 部分测试图像

标注标签的数据格式是 x、y、z、横滚角、俯仰角、偏航角。第 *i* 行对应第 *i* 张图像。其中相机位置是通过激光测距仪和卷尺测量出来的，相机的三轴姿态角则是通过水平仪测量的。使用数据集中少量图像进行建图，建图结果如图 4-13 所示。

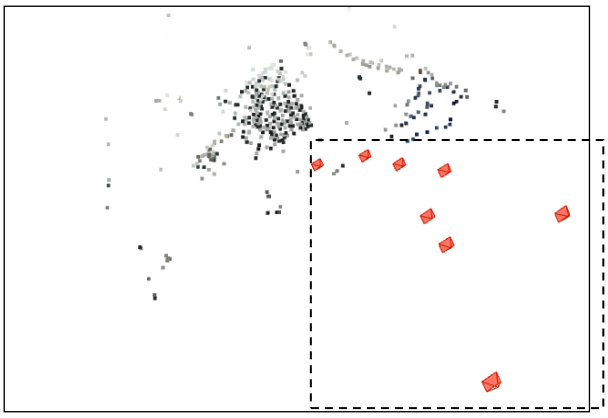

图 4-13 离线建图结果

图 4-13 中黑灰色散点是对数据库图像的匹配 2D 点三角化得到的 3D 点，虚线框出的金字塔则表示由相机感光器件和位姿决定的相机视点。金字塔的顶点表示的则是相机光心的位置。

在建图的过程中，建图图像的位姿也同时被估计出来，但是其参考系并不一定与应用场景的需求相符合，因此通常会依据建图图像的位置标签计算坐标变换矩阵。只有已知参考系变换后，才可实现对位姿估计精度的评估。统计测试图像在线定位时的位姿估计误差，空间位置误差和欧拉角表示的姿态角误差的累积概率分布分别如图 4-14 (a)、图 4-14 (b)所示。

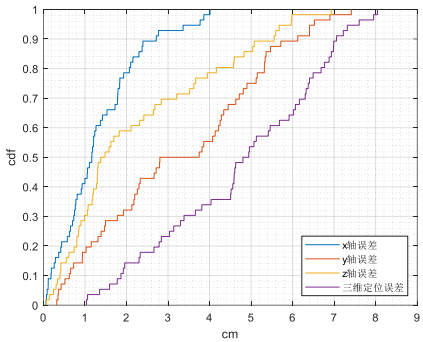

(a) 位置估计误差累积概率分布

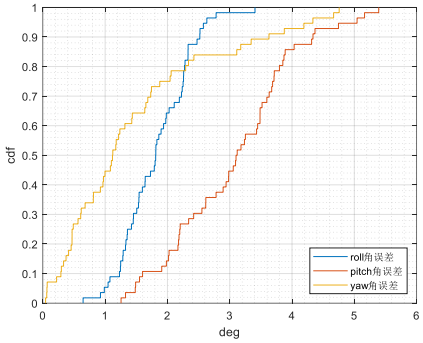

(b) 姿态估计误差累积概率分布

图 4-14 位姿估计误差累积概率分布

图 4-14 (a)、图 4-14 (b)中的三轴位置和姿态角误差是将算法位姿估计结果与提前测量的真实位姿对应作差得到，图 4-14 (a)中的三维定位误差则是位置误差的 L2 范数。图中横坐标都表示阈值，纵坐标都表示误差小于该阈值的结果占比。由图 4-14 中结果可知，本文方法在自建室内数据集中的定位误差能保持在 8.5cm 以内，三轴姿态角误差也均在 5.5 度以内。可见本文方法应用到室内场景也能取得较好的性能。在该数据集下定位，本文方法总耗时 480ms，hloc 方法总耗时 401ms。通过以上实验，验证了本文所提单目相机位姿估计估计系统的实用性。